



LOMBREA ANCA RALUCA
OPREA FELICIA
PASCALAU RAZVAN CRISTIAN

36/12





PROIECT IDENTIFICAREA SISTEMELOR

ARX neliniar



1.Introducere

2.Structura metodei ARX neliniare

3.Algoritm

4.Rezultate de reglare

5.Concluzie

1. Introducere – ARX neliniar

- Model autoregresiv cu intrare exogenă
- Model parametric de tip polinomial
- Ieșirea $y(k)$ la pasul curent este o combinație neliniară cu ponderi a și b între ieșirile și intrările anterioare ale sistemului.
- Un model de grad m conține produse între variabilele întârziate al căror grad este maxim m și este liniar în parametrii.

2. NARX polinomial

- $y(k) = g(y(k-1), y(k-2), \dots, y(k-na), u(k-1), u(k-2), \dots, u(k-nb); \theta) + e(k)$
- $y(k) = g(d(k); \theta) + e(k)$
- $\theta \in \mathbb{R}^{na+nb}$: parametrii aleși potrivit pentru identificarea unui sistem dinamic neliniar
- $\theta = [a_1 \dots a_{na} \ b_1 \dots b_{nb}]^T$
- g este un polinom de grad m ale cărui variabile sunt ieșirile și intrările precedente, iar coeficienții sunt parametrii θ
- $d(k) = [y(k-1) \dots y(k-na) \ u(k-1) \dots u(k-nb)]^T = \varphi(k)$, vector de regresori

Exemplu NARX polinomial

- $na = nb = 1, m = 1$

$$y(k) = a_1 y(k-1) + b_1 u(k-1) + c_1 + e(k)$$

- $na = nb = 2, m = 2$

$$\begin{aligned} y(k) = & a_1 y(k-1) + a_2 y(k-2) + a_3 y(k-1)^2 + a_4 y(k-2)^2 + \\ & + b_1 u(k-1) + b_2 u(k-2) + b_3 u(k-1)^2 + b_4 u(k-2)^2 + \\ & + c_1 y(k-1) u(k-1) + c_2 y(k-1) u(k-2) + c_3 y(k-2) u(k-1) + \\ & + c_4 y(k-2) u(k-2) + d + e(k) \end{aligned}$$

Predicție și simulare

- Predicție cu un pas înainte

$$\mathbf{x}(k) = [y(k-1) \ y(k-2) \ \dots \ y(k-n_a) \ u(k-1) \ u(k-2) \ \dots \ u(k-n_b)]^T$$

$$\hat{y}_{\text{pred}}(k) = g(\mathbf{d}(k); \theta)$$

- Simulare

$$\hat{\mathbf{x}}(k) = [\hat{y}(k-1) \ \hat{y}(k-2) \ \dots \ \hat{y}(k-n_a) \ u(k-1) \ u(k-2) \ \dots \ u(k-n_b)]^T$$

$$\hat{y}_{\text{sim}}(k) = g(\hat{\mathbf{d}}(k); \theta)$$

- Ieșirile simulate la momente negative sau 0 sunt egale cu 0!

3. Algoritm

- $X(k) = [y(k-1) \ y(k-2) \ \dots \ y(k-n_a) \ u(k-1) \ u(k-2) \ \dots \ u(k-n_b)], \ k \in \mathbb{R}^n$

$$X(k) = [x_1(k) \ x_2(k) \ x_3(k) \ \dots \ x_n(k)], \quad n = n_a + n_b$$

- $\varphi(k) = \prod_{i=1}^n x_i^{p_i}(k), \quad p \in (0, 1 \ \dots \ m)$

$$\varphi(k) = x_1^{p_1}(k) \ x_2^{p_2}(k) \ x_3^{p_3}(k) \ \dots \ x_n^{p_n}(k), \quad \sum_{i=1}^n p_i \leq m$$

- Se calculează $X(k)$ și $\varphi(k)$ atât pentru datele de identificare, cât și pentru cele de validare

Exemplu

Pentru $n_a = n_b = 1, m = 2$

$$P = \begin{bmatrix} 0 & 0 \\ 0 & 1 \\ 1 & 0 \\ 1 & 1 \\ 2 & 0 \\ 0 & 2 \\ 2 & 1 \\ 1 & 2 \\ 2 & 2 \end{bmatrix}$$

$$\phi = \begin{bmatrix} x_1^0(1) x_2^0(1) & x_1^0(1) x_2^1(1) & x_1^1(1) x_2^0(1) & x_1^1(1) x_2^1(1) & x_1^2(1) x_2^0(1) & x_1^0(1) x_2^2(1) \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_1^0(n) x_2^0(n) & x_1^0(n) x_2^1(n) & x_1^1(n) x_2^0(n) & x_1^1(n) x_2^1(n) & x_1^2(n) x_2^0(n) & x_1^0(n) x_2^2(n) \end{bmatrix}$$

Formare matrice regresori:

$$\varphi(k) = \prod_{i=1}^{n_a+n_b} x_i^{p(l,i)}(k,i)$$

l = numărul de linii unde $\sum_{i=0}^n p_i \leq 2$

Se vor alege primele 6 linii din matricea P pentru care suma elementelor de pe fiecare coloană este $\leq m$.

- Aflarea regresorilor și a parametrilor

ϕ_{id} folosind datele de identificare

ϕ_{val} folosind datele de validare

$$\theta = \phi_{id} \setminus y_{identificare}$$

- Aflarea predicției

$$\hat{y}_{pred} = \phi * \theta$$

- Aflarea simulării

$$\hat{y}_{sim}(1) = [-\hat{y}_{sim}(0) \dots -\hat{y}_{sim}(1-na) \ u(0) \dots u(1-nb)]$$

$$\hat{y}_{sim}(2) = [-\hat{y}_{sim}(1) \dots -\hat{y}_{sim}(2-na) \ u(1) \dots u(2-nb)]$$

...

$$\hat{y}_{sim}(n) = [-\hat{y}_{sim}(n) \dots -\hat{y}_{sim}(n-na) \ u(n) \dots u(n-nb)]$$

Rezultate de reglare

Eroarea medie pătratică pe datele de **identificare** pentru $y_{\text{predicție}}$

	m=1	m=2	m=3	m=4
na=nb=1	0.512	0.0344	0.0334	0.0334
na=nb=2	0.326	1.53e-04	8.38e-06	7.20e-06
na=nb=3	0.232	5.32e-06	4.32e-06	3.75e-06

Eroarea medie pătratică pe datele de **identificare** pentru y_{simulare}

	m=1	m=2	m=3	m=4
na=nb=1	0.676	0.431	0.430	0.425
na=nb=2	0.402	5.20e-03	5.29e-04	5.05e-04
na=nb=3	0.285	NaN	NaN	NaN

Rezultate de reglare

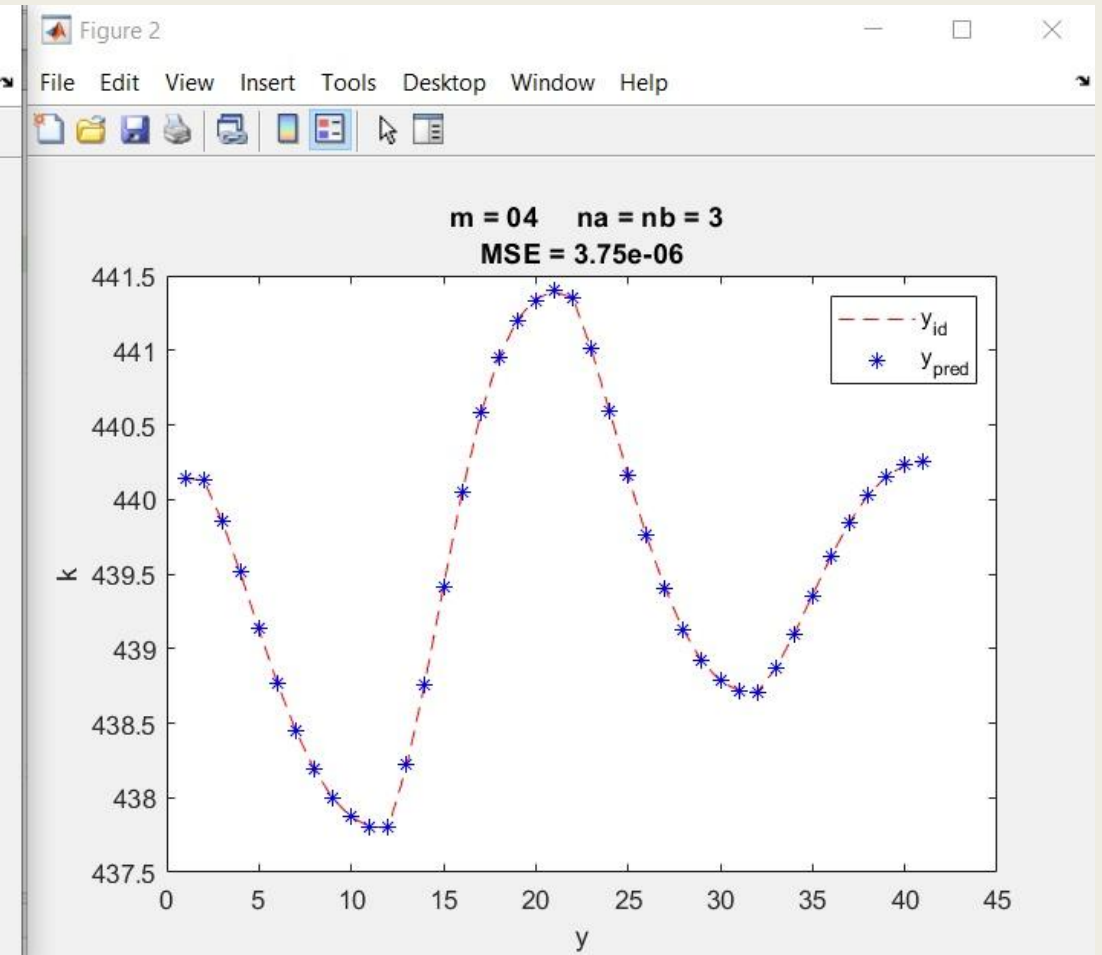

Eroarea medie pătratică pe datele de **validare** pentru $y_{\text{predicție}}$

	m=1	m=2	m=3	m=4
na=nb=1	0.291	0.016	0.0157	0.0157
na=nb=2	0.164	4.97e-05	6.45e-06	7.66e-06
na=nb=3	0.0994	4.41e-06	5.40e-06	6.06e-06

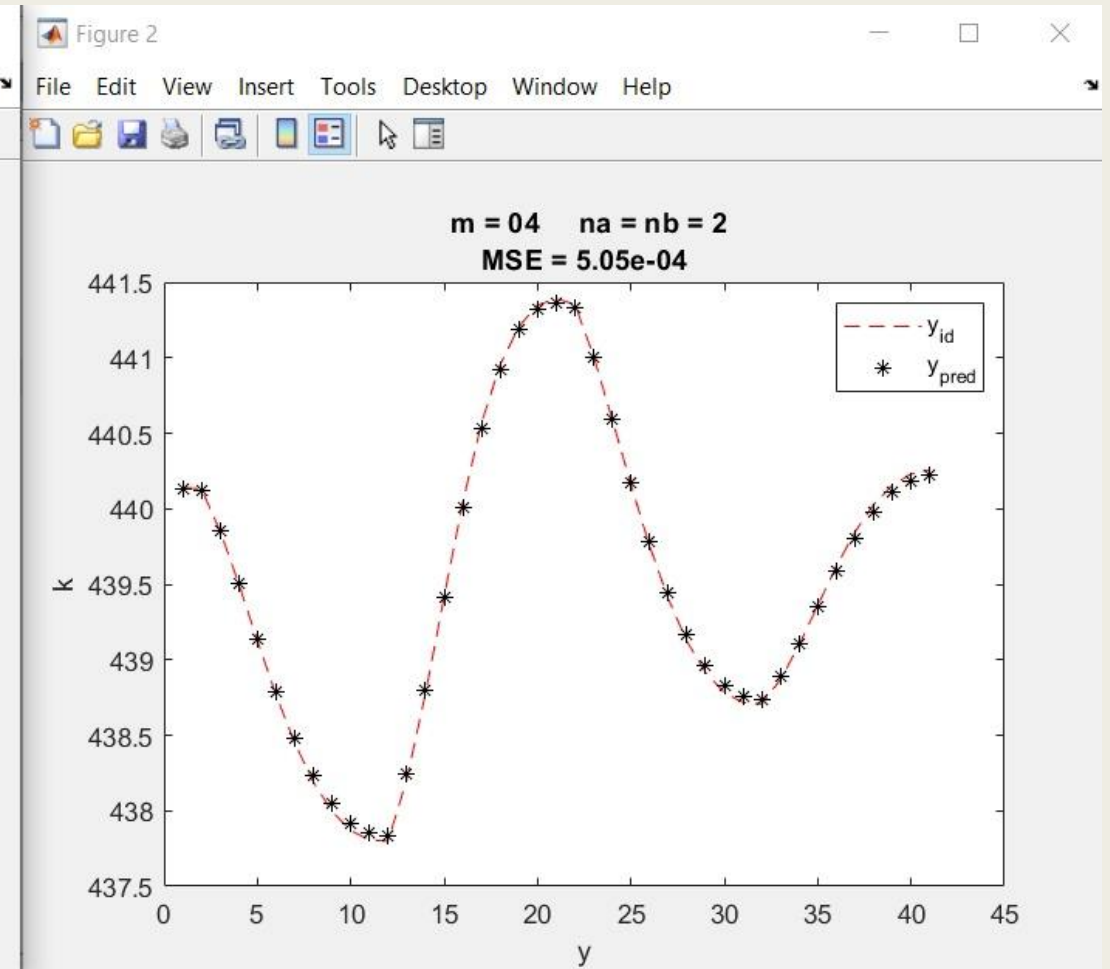
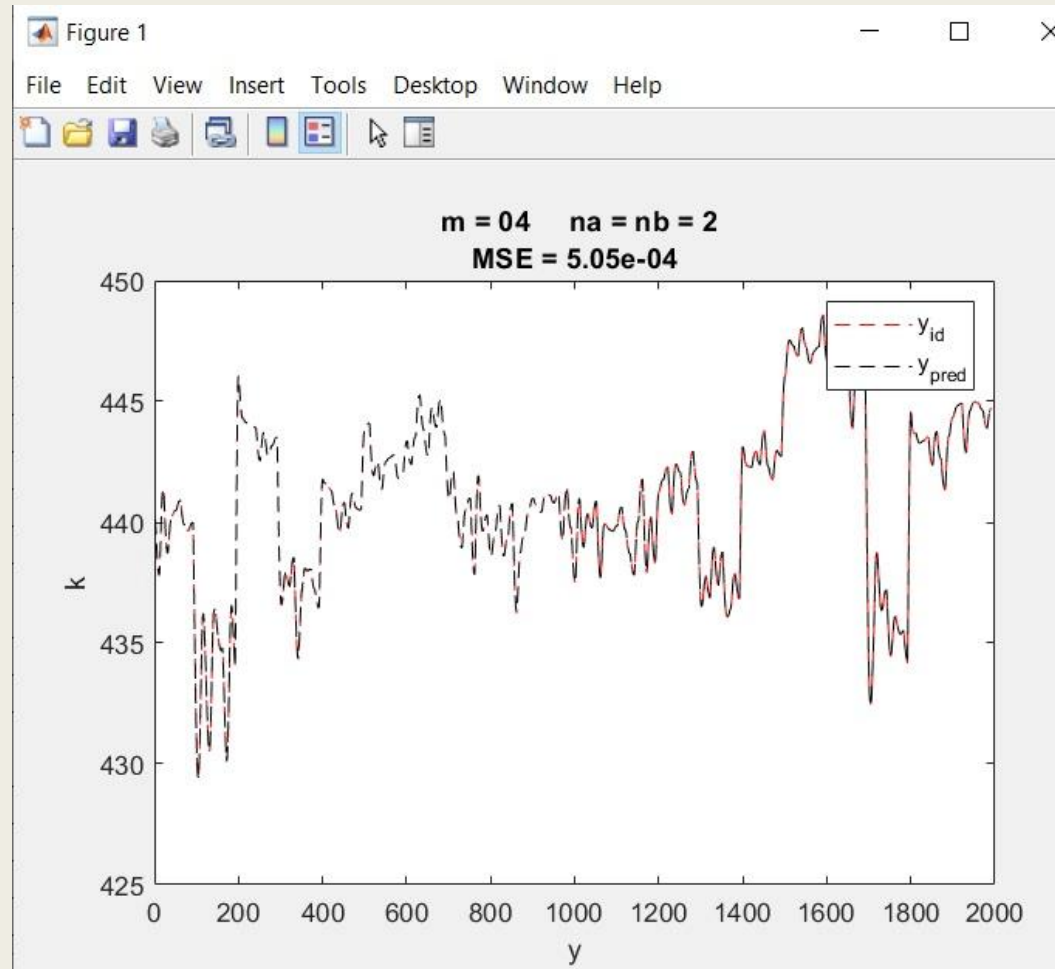
Eroarea medie pătratică pe datele de **validare** pentru y_{simulare}

	m=1	m=2	m=3	m=4
na=nb=1	0.380	0.217	0.188	0.183
na=nb=2	0.196	NaN	NaN	NaN
na=nb=3	0.117	NaN	NaN	NaN

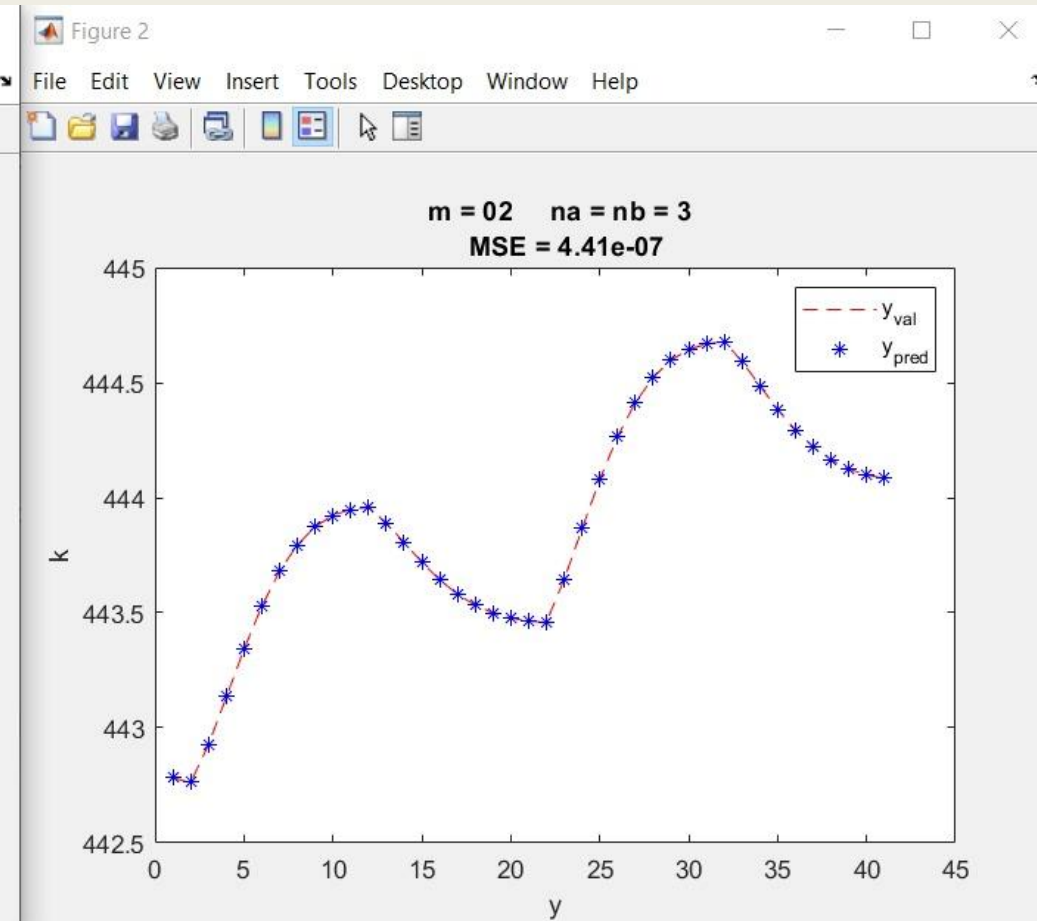

■ Cel mai bun caz de predicție pentru datele de identificare



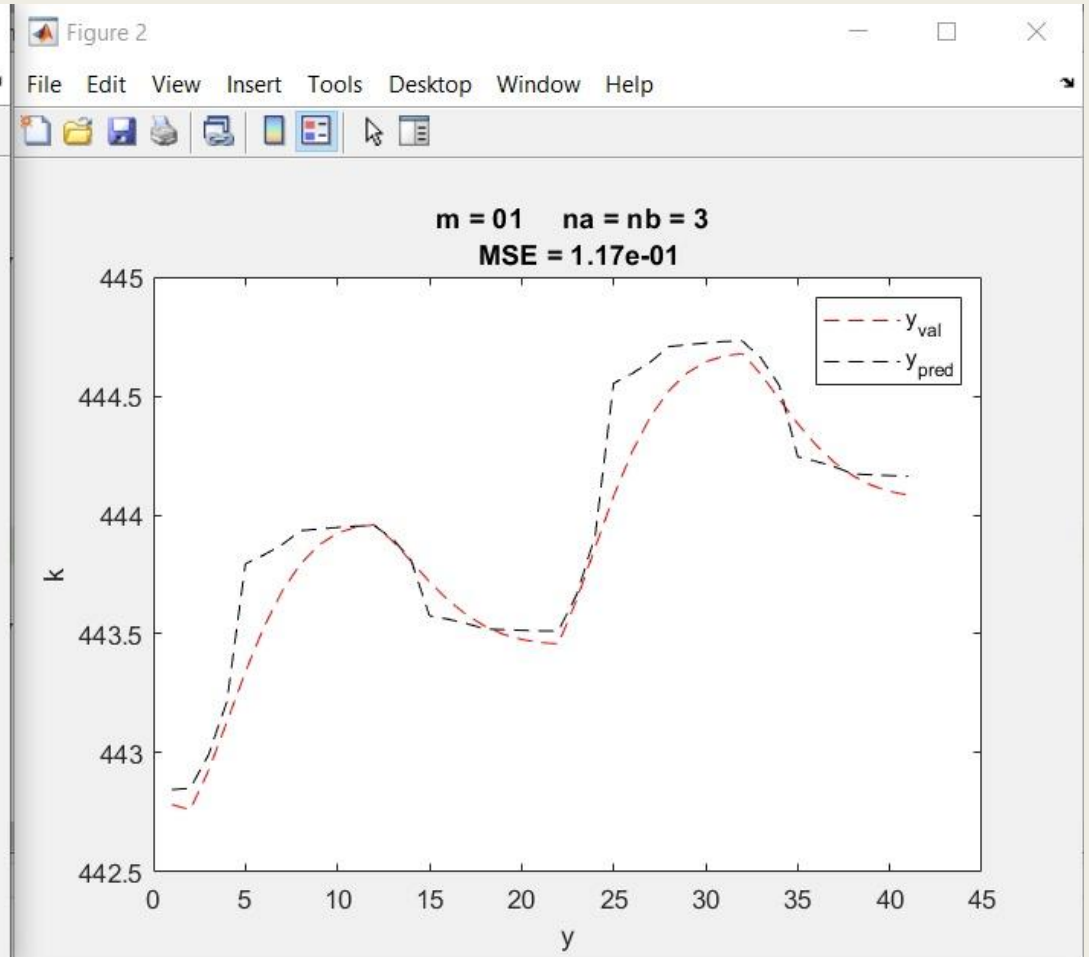
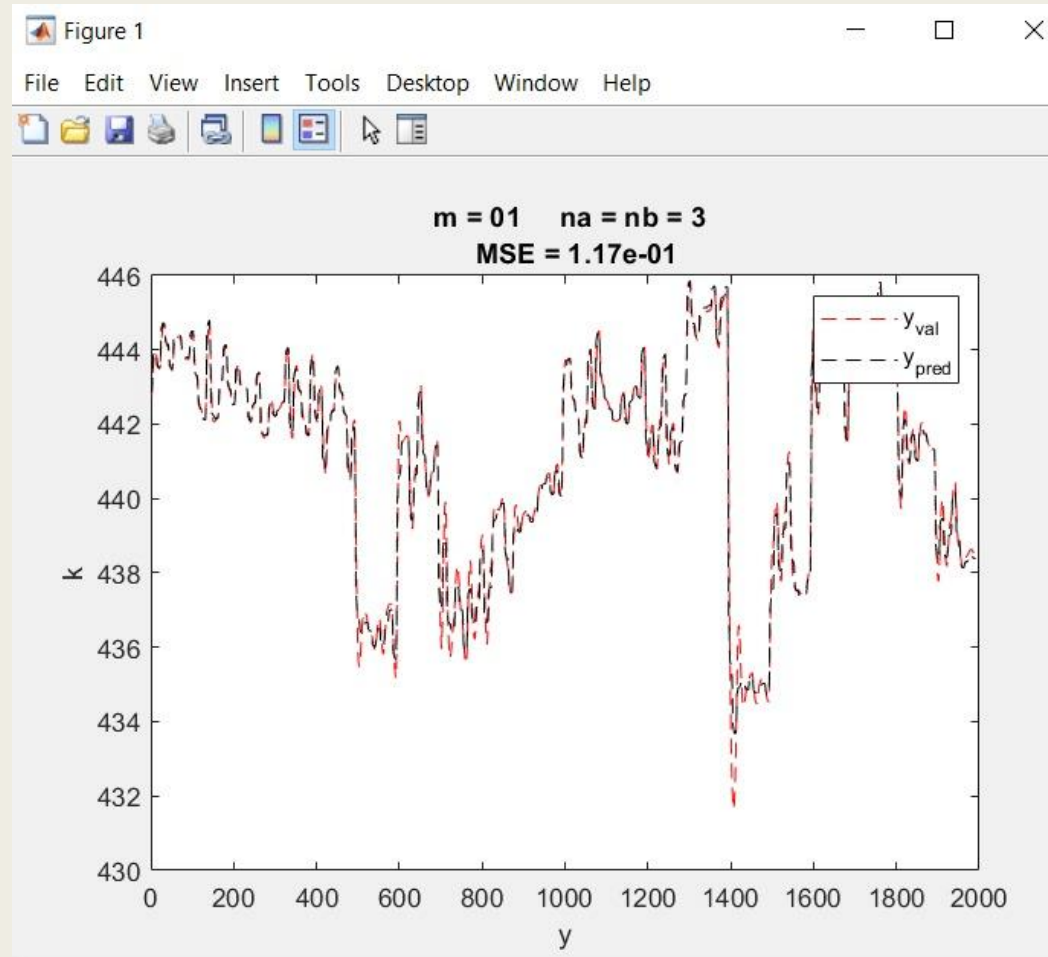
Cel mai bun caz de simulare pentru datele de identificare



■ Cel mai bun caz de predicție pentru datele de validare



■ Cel mai bun caz de **simulare** pentru datele de **validare**



5. Concluzie

- Pentru predicție, MSE scade odată cu creșterea gradului sau cu a ordinelor n_a și n_b , iar cele mai bune rezultate se obțin pentru gradul $m=4$ și ordinul $n_a=n_b=3$.
- Pentru simulare pe datele de identificare MSE_{sim} scade asemănător cu MSE_{pred} , dar odată cu depășirea gradului 2 pentru ordin ≥ 3 nu se mai obțin rezultate datorită instabilității sistemului.
- Simularea pe datele de validare produce rezultate valide pentru o gamă mai restrânsă de combinații între m și $n_a=n_b$.